METAGENOMIC ANALYSIS: HUMAN INFANT MICROBIOTA

Objetivo del estudio

En este estudio se emplearon los datos simplificados del estudio ECAM (https://doi.org/10.1126/scitranslmed.aad7121), un estudio longitudinal de la microbiota de lactantes y madres desde el nacimiento hasta los dos años de vida. El objetivo del estudio es estudiar la microbiota de los infantes a los doce meses, para identificar posibles variaciones en en función de distintas variables, así como hallar el significado biológico de estas variaciones.

Resultados y discusión

Prefiltrado

Antes de comenzar con el análisis de prefiltrado, fue necesario preparar los archivos necesarios para el estudio. En primer lugar, se elaboró un archivo **manifest.tsv**, que contiene los identificadores de las muestras junto con la ruta de acceso a los archivos de secuenciación para su correspondiente descarga. Por otro lado, se preparó el archivo **metadata.tsv,** que contiene los datos del estudio, incluyendo las variables "sample-id", identificador único de cada muestra; "anti_exposed_all", que indica si el niño estuvo expuesto a antibióticos (y) o no (n); "delivery", correspondiente al tipo de parto (Vaginal o Cesárea); "month", que señala el momento de la recogida de la muestra (al nacer o a los 12 meses); "sex", con el sexo del infante (Masculino o Femenino); y "studyid", que representa un identificador único por individuo.

	A	B
1	sample-id	absolute-filepath
2	10249.C001.01SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C001.01SS.fastq.gz
3	10249.C001.18SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C001.18SS.fastq.gz
4	10249.C002.01SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C002.01SS.fastq.gz
5	10249.C002.13SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C002.13SS.fastq.gz
6	10249.C004.01SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C004.01SS.fastq.gz
7	10249.C004.15SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C004.15SS.fastq.gz
8	10249.C005.01SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C005.01SS.fastq.gz
9	10249.C005.14SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C005.14SS.fastq.gz
10	10249.C007.01SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C007.01SS.fastq.gz
11	10249.C007.17SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C007.17SS.fastq.gz
12	10249.C008.01SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C008.01SS.fastq.gz
13	10249.C008.12SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C008.12SS.fastq.gz
14	10249.C009.01SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C009.01SS.fastq.gz
15	10249.C009.13SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C009.13SS.fastq.gz
16	10249.C010.01SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C010.01SS.fastq.gz
17	10249.C010.15SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C010.15SS.fastq.gz
18	10249.C011.01SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C011.01SS.fastq.gz
19	10249.C011.12SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C011.12SS.fastq.gz
20	10249.C012.01SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C012.01SS.fastq.gz
21	10249.C012.15SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C012.15SS.fastq.gz
22	10249.C014.01SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C014.01SS.fastq.gz
23	10249.C014.13SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C014.13SS.fastq.gz
24	10249.C016.01SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C016.01SS.fastq.gz
25	10249.C016.15SS	/home/vdi/Descargas/microbiota/equipo/fastq/10249.C016.15SS.fastq.gz

Figura 1. Visualización de las secuencias importadas al entorno QIIME2. Archivo manifest.tsv.

	A	B	C	D	E	F
1	sample-id	anti_exposed_all	delivery	month	sex	studyid
2	#q2:types	categorical	categorical	caterogic	categorical	categorical
3	10249.C001.01SS	n	Vaginal	0	Female	1
4	10249.C001.18SS	y	Vaginal	12	Female	1
5	10249.C002.01SS	n	Cesarean	0	Male	2
6	10249.C002.13SS	n	Cesarean	12	Male	2
7	10249.C004.01SS	n	Cesarean	0	Male	4
8	10249.C004.15SS	y	Cesarean	12	Male	4
9	10249.C005.01SS	n	Cesarean	0	Female	5
10	10249.C005.14SS	n	Cesarean	12	Female	5
11	10249.C007.01SS	n	Cesarean	0	Male	7
12	10249.C007.17SS	y	Cesarean	12	Male	7
13	10249.C008.01SS	n	Vaginal	0	Male	8
14	10249.C008.12SS	y	Vaginal	12	Male	8
15	10249.C009.01SS	n	Vaginal	0	Male	9
16	10249.C009.13SS	n	Vaginal	12	Male	9
17	10249.C010.01SS	n	Vaginal	0	Male	10
18	10249.C010.15SS	y	Vaginal	12	Male	10
19	10249.C011.01SS	n	Cesarean	0	Female	11
20	10249.C011.12SS	n	Cesarean	12	Female	11
21	10249.C012.01SS	n	Cesarean	0	Female	12
22	10249.C012.15SS	y	Cesarean	12	Female	12
23	10249.C014.01SS	n	Vaginal	0	Male	14
24	10249.C014.13SS	n	Vaginal	12	Male	14

Figura 2. Visualización de las variables incluidas en el archivo de metadatos. Archivo metadata.tsv.

A continuación, se llevó a cabo el preprocesamiento de los archivos de secuenciación correspondientes a la región V4 del gen 16S rRNA (lecturas forward). Esta fase de prefiltrado es necesaria para asegurar que la calidad de las lecturas sea adecuada en los análisis posteriores.

Tras ejecutar los programas FastQC y MultiQC, se observa que la calidad media por base de las secuencias (Figura 1) mantiene puntuaciones superiores a 30 a lo largo de toda la longitud de lectura. Esto indica una calidad de secuenciación elevada y homogénea, por lo que no se consideró necesario realizar recortes adicionales.

Además, al analizar manualmente las líneas de calidad de los archivos FASTQ, se comprobó que los caracteres presentes en dichas líneas se encuentran principalmente entre ‘A’ y ‘H’, los cuales corresponden a las puntuaciones más altas en la codificación Phred+33, según la tabla ASCII.

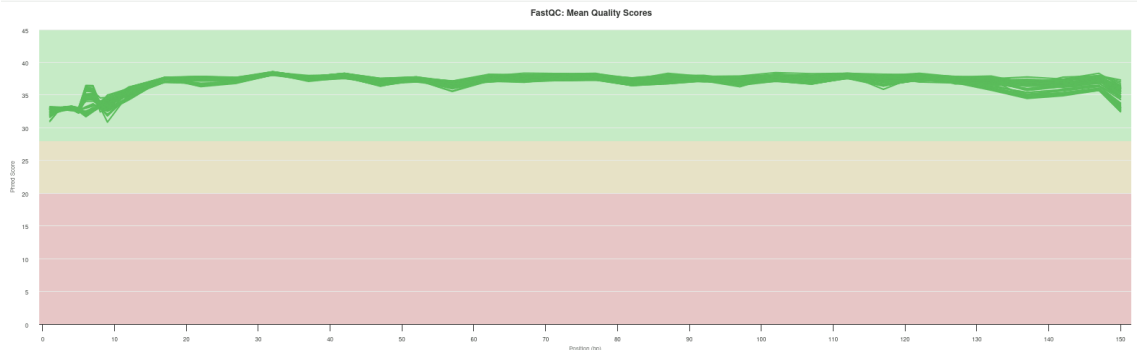

Figura 3. Histograma de calidad de secuencias. Se muestra el valor medio de calidad (Phred) en cada posición de la lectura, el cual se mantiene por encima de 30 en todas las posiciones, indicando una alta fidelidad en las secuencias analizadas

Por otro lado, se presenta la distribución de lecturas por muestra, donde se observa un amplio rango de recuentos. Todas las muestras cuentan con más de 10.000 lecturas, aunque algunas alcanzan valores superiores a 50.000 (Figura 4).

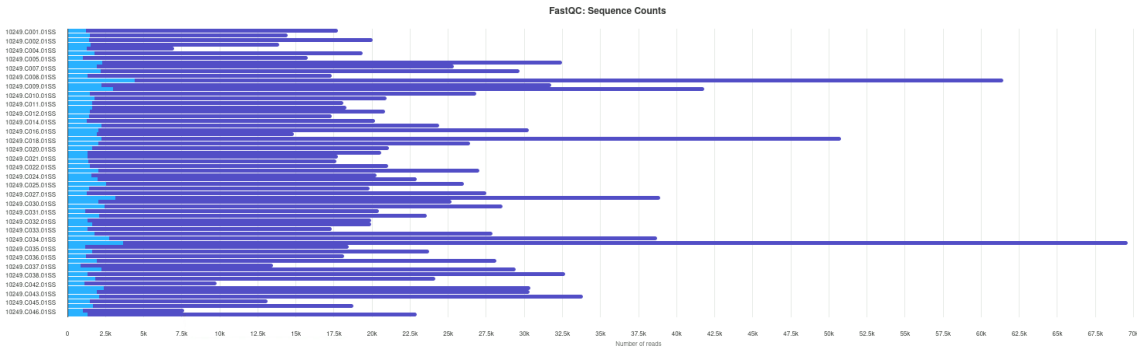

Figura 4. Número de lecturas por muestra. Se observa una variabilidad considerable en la profundidad de secuenciación entre muestras, lo que justifica la aplicación de un proceso de normalización mediante rarefacción.

Una vez verificada la calidad de las secuencias, se procedió con el análisis de *denoising* utilizando el método DADA2. Este análisis permite inferir la secuencia biológica exacta y eliminar el ruido del conjunto de datos mediante la corrección de errores. Como resultado, se obtienen las secuencias ASVs (*Amplicon Sequence Variants*), que representan secuencias únicas y exactas, constituyendo una mejor alternativa frente a los tradicionales OTUs.

Tras importar las secuencias y visualizarlas mediante QIIME2, se generaron tres archivos fundamentales: **dada2_stats.qza**, que recoge las estadísticas de eliminación de ruido, permitiendo revisar cuántas secuencias se han filtrado en cada paso del proceso; **dada2_table.qza**, que contiene la tabla de frecuencias, donde se resumen los recuentos asociados a cada muestra y cada ASV y el archivo **dada2_rep_set.qza** que almacena las secuencias representativas de cada ASV, además de ser útil para controlar la longitud de las secuencias.

sample-id	input	filtered	percentage of input passed filter	denoised	non-chimeric
#q2:types	numeric	numeric	numeric	numeric	numeric
10249.C001.01SS	17742	14714	82.93	14645	14645
10249.C001.18SS	14481	13164	90.91	13077	12438
10249.C002.01SS	20053	16615	82.86	16576	16576
10249.C002.13SS	13916	12246	88	12172	11580
10249.C004.01SS	6982	4603	65.93	4575	4575
10249.C004.15SS	19400	16817	86.69	16679	14724
10249.C005.01SS	15759	13184	83.66	13155	13155
10249.C005.14SS	32478	29206	89.93	29047	27333
10249.C007.01SS	25378	20897	82.34	20846	20846

Figura 5. Visualización del archivo dada2_stats.qzv. Se muestra el número de secuencias iniciales, filtradas, denoised y no quiméricas por muestra. La mayoría de las muestras presenta tasas de retención superiores al 80%, lo que indica un buen rendimiento del proceso de filtrado y eliminación de ruido. Archivo: dada2_stats.qzv.

qiime2view File: dada2_table.qzv ×

Overview | Interactive Sample Detail | Feature Detail

Table summary

Metric	Sample
Number of samples	64
Number of features	1,927
Total frequency	1,284,901

Frequency per sample

	Frequency
Minimum frequency	4,575.0
1st quartile	14,742.75
Median frequency	17,614.5
3rd quartile	23,282.5
Maximum frequency	58,839.0
Mean frequency	20,076.578125

Figura 6. Visualización del archivo dada2_table.qzv**.** Se observa principalmente el número total de muestras (64), el número de ASV detectadas (1.927) y la frecuencia total.

qiime2view File: dada2_rep_set.qzv × Visualization Citations Provenance Metadata

Sequence Length Statistics

Download sequence-length statistics as a TSV

Sequence Count	Min Length	Max Length	Mean Length	Range	Standard Deviation
1927	150	150	150.0	0	0.0

Seven-Number Summary of Sequence Lengths

Download seven-number summary as a TSV

Percentile:	2%	9%	25%	50%	75%	91%	98%
Length* (nts):	150	150	150	150	150	150	150

*Values rounded down to nearest whole number.

Sequence Table

To BLAST a sequence against the NCBI nt database, click the sequence and then click the *View report* button on the resulting page.

Download your sequences as a raw FASTA file

Click on a Column header to sort the table.

Feature ID	Sequence Length	Sequence
04195686f2b70585790ec75320de0d6f	150	TACGGAGGGTGCAAGCGTTAATCGGAATTACTGGGCGTAAAGCGCACGCAGGCGGTTTGTTAAGTCAGATGTGAAATCCCCGGGCTCAACCTGGGAACTGCATCTGATACTGGCAAGCTTGAGTCTCGTAGAGGGGGGTAGAATTCCAGG
ac5402de1ddf427ab8d2b0a8a0a44f19	150	TACGGAGGATCCGAGCGTTATCCGGATTTATTGGGTTTAAAGGGAGCGTAGATGGATGTTTAAGTCAGTTGTGAAAGTTTGCGGCTCAACCGTAAAATTGCAGTTGATACTGGATATCTTGAGTGCAGTTGAGGCAGGCGGAATTCGTGG
e2c3ff4f647112723741aa72087f1bfa	150	TACGTAGGGTGCAAGCGTTATCCGGAATTATTGGGCGTAAAGGGCTCGTAGGCGGTTCGTCGCGTCCGGTGTGAAAGTCCATCGCTTAACGGTGGATCCGCGCCGGGTACGGGCGGGCTTGAGTGCGGTAGGGGAGACTGGAATTCCCGG

Figura 7. Visualización del archivo dada2_rep_set.qzv. Se aprecia la longitud de las secuencias representativas, observándose que todas presentan una longitud constante de 150 nucleótidos, sin variabilidad.

Normalización

Cabe mencionar que, debido a la presencia de dos muestras por individuo (una tomada al nacimiento y otra a los 12 meses), fue necesario modificar el archivo de metadatos original, generando una nueva versión (**metadata_2.tsv**) que incluyera únicamente las muestras correspondientes a los 12 meses. Esto se debe a que no es adecuado comparar muestras del mismo individuo tomadas en diferentes momentos.

Para el estudio de la diversidad microbiana de las muestras, fue necesario normalizar los datos, con el fin de evitar la desigualdad en la profundidad de secuenciación entre muestras. Para ello, se empleó la **rarefacción**, como método de normalización para alcanzar una profundidad uniforme en todas las muestras.

Como valores de frecuencia mínima y máxima se establecieron 50 y 12.000, respectivamente, empleando los valores de frecuencia por muestra de los distintos ASVs como referencia. (Figura 8). Esto se llevó a cabo para filtrar las muestras que están por debajo de la profundidad de rarefacción.

Table summary

Metric	Sample
Number of samples	32
Number of features	616
Total frequency	711,497

Frequency per sample

	Frequency
Minimum frequency	11,580.0
1st quartile	16,412.75
Median frequency	20,009.0
3rd quartile	24,276.5
Maximum frequency	58,839.0
Mean frequency	22,234.28125

Frequency per sample detail (csv | html)

Figura 8. Resumen de las frecuencias de los distintos ASVs del estudio, representando medidas importantes como los cuartiles, frecuencias mínimas y máximas o el número de muestras. Archivo: dada2_table.qzv, tras modificar el archivo de metadatos original.

Este paso genera distintas curvas de rarefacción que nos permiten ver cuando las muestras alcanzan el nivel de saturación de riqueza en función de las distintas variables, pudiendo ajustar mejor el valor máximo de profundidad de muestreo adecuado (Figura 9).

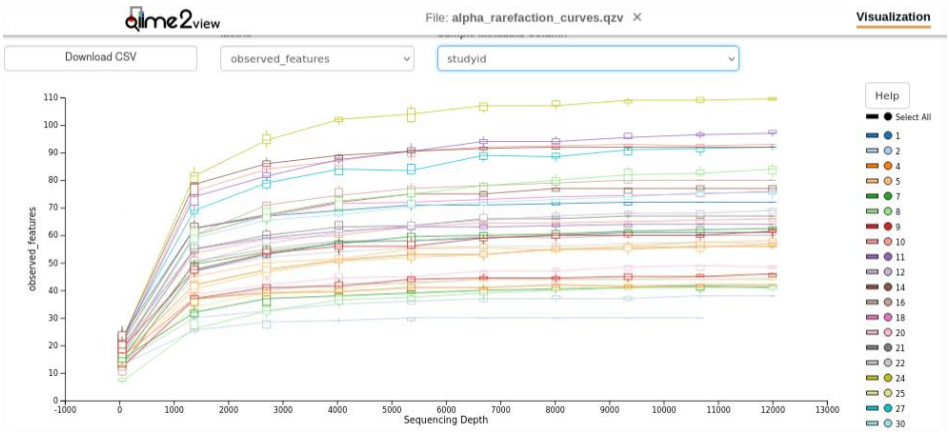

Figura 9. Curva de rarefacción de las distintas muestras filtradas por "observed features" y agrupadas según la variable "studyid". Archivo: alpha_rarefaction_curves.qzv.

Además, si nos fijamos en la variable "anti_exposed_all" (Figura 10), podemos apreciar que hay un repunte alrededor de la profundidad de secuenciación de 12.000 lecturas. En nuestro caso, se consideró que el balance coste/posibilidad de mejor análisis justificaba el aumentar la profundidad de secuenciación escogida hasta dicho punto, aunque supusiera perder una muestra cómo puede verse en el gráfico inferior.

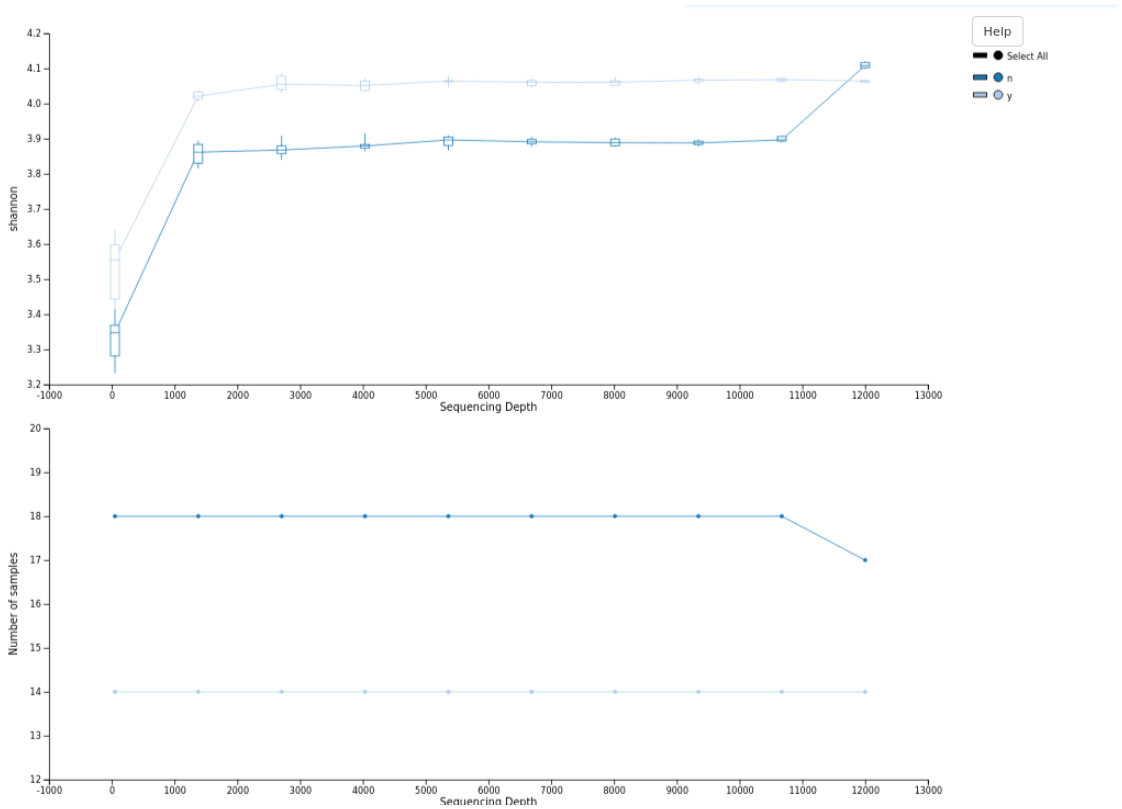

Figura 10. Curva de rarefacción filtrada por la variable variable "anti_exposed_all". La parte superior muestra el índice Shannon, es decir la diversidad. La parte inferior indica el número de muestras. Se puede apreciar que se pierde una muestra sobre las 12.000 lecturas. Archivo: alpha_rarefaction_curves.qzv.

Con el objetivo de maximizar las secuencias retenidas, se analizó el archivo "dada2_table.qzv" para determinar la profundidad exacta a partir de la cual se empiezan a perder tantas muestras que aumentar la profundidad de secuenciación deja de ser beneficioso. Como puede verse en la imagen (Figura 11), dicho valor corresponde a 12140 lecturas.

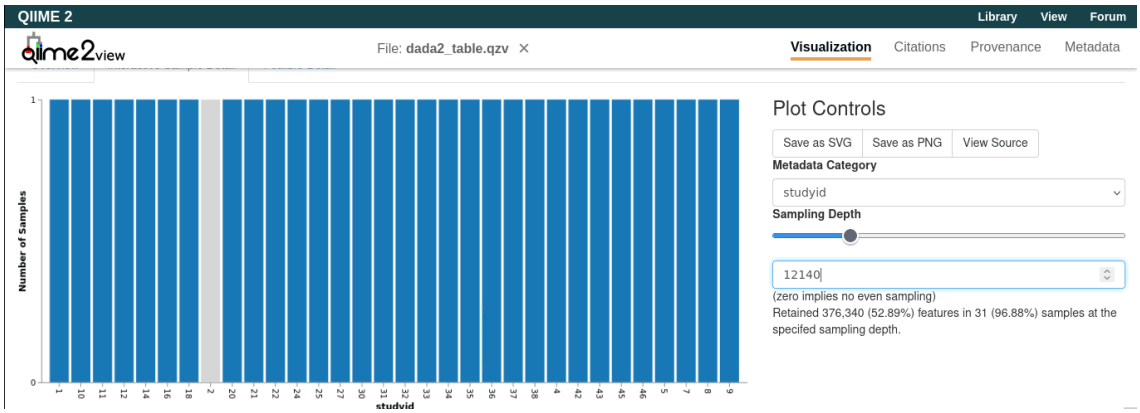

Figura 11. Representación del número de muestras del estudio a medida que se va cambiando la profundidad de secuenciación. El valor de 12.140 es la profundidad límite antes de perder un número significativo de muestras. Archivo: dada2_table.qzv.

Tras elegir el valor adecuado de profundidad de muestreo, se normalizaron los datos con la tabla de ASVs a una profundidad de 12.140 lecturas por muestra, generando así una nueva tabla procesada que será utilizada en los análisis posteriores (Figura 12).

Figura 12. Resumen de la tabla de ASVs tras la normalización por rarefacción a una profundidad de 12.140 lecturas por muestra. Archivo: rar_table.qzv.

Análisis de alfa y beta diversidad

Para cuantificar la diversidad de especies dentro de cada muestra y entre distintas muestras, se emplearon los índices de diversidad alfa y beta, respectivamente.

Analizando los distintos índices de diversidad alfa, se pudo apreciar que la única variable que mostró diferencias significativas fue “delivery”, a diferencia de las variables “sex” y “anti_exposed_all”.

Respecto al índice de Shannon, que proporciona información tanto sobre la riqueza como sobre la equidad de las especies en una muestra (teniendo en cuenta la abundancia relativa), se observó una mayor diversidad en el grupo vaginal. Esto indica una comunidad microbiana más diversa y una distribución más uniforme de las especies (p-valor = 0.00205) (Figura 13).

Figura 13. Gráfico de cajas y bigotes que muestra la entropía de Shannon en dos grupos en función de la variable “delivery”.

Por su parte, el índice de Evenness proporciona información sobre cuán uniformemente están distribuidas las especies dentro de una comunidad microbiana. Se observa que el grupo vaginal presenta un valor más alto de evenness (p-valor = 0.0186), lo que indica que las especies microbianas están distribuidas de forma más uniforme, a diferencia del grupo cesárea, que muestra una menor equidad, lo que sugiere que algunas especies son mucho más abundantes que otras.

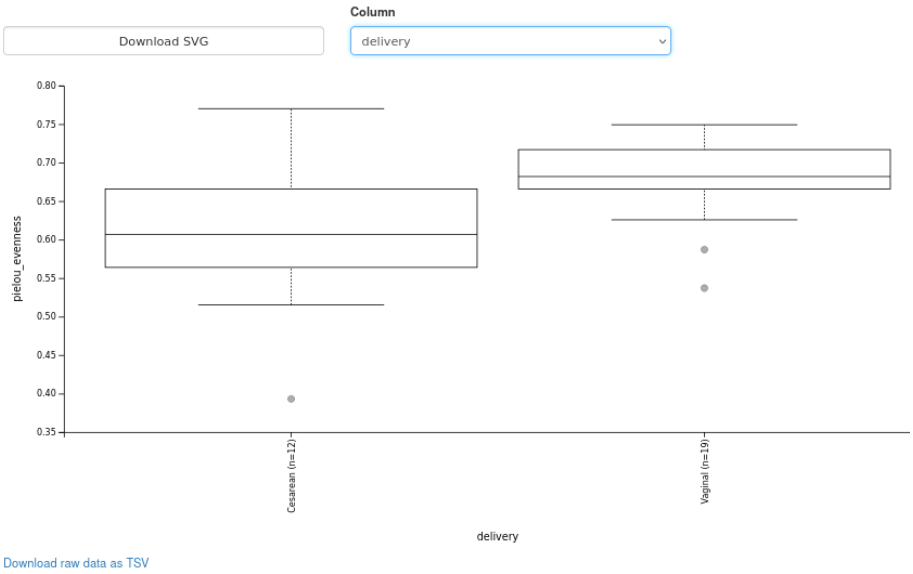

Kruskal-Wallis (all groups)

	Result
H	5.5328947368420955
p-value	0.018662205147194744

Figura 14. Gráfico de cajas y bigotes que muestra el índice de Evenness en dos grupos en función de la variable "delivery".

Por último, el índice de "observed features" representa el número de ASVs únicos encontrados por muestra, es decir, una medida de la riqueza de cada muestra. Como se puede observar, el grupo vaginal presenta una mayor riqueza en comparación con los nacimientos por cesárea (p-valor =0.00285).

Figura 15. Gráfico de cajas y bigotes que muestra el índice de Observed Features en dos grupos en función de la variable “delivery”.

A continuación, se analizaron los índices de diversidad beta. En primer lugar, el índice de Bray-Curtis evalúa las diferencias en la composición de especies entre dos comunidades, teniendo en cuenta la abundancia relativa de las especies. En la visualización generada con Emperor, se observa que la variable “delivery” es la que mejor describe el compartimiento de las muestras.

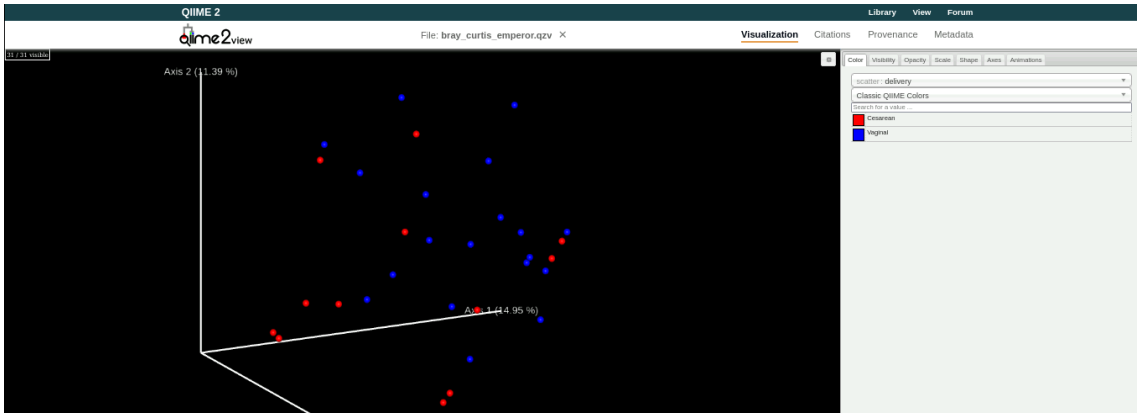

Figura 16. Matriz de puntos en 3D que representa la diversidad beta en dos grupos en función de la variable "delivery". Archivo: bray_curtis_emperor.qzv.

Por otro lado, para verificar que las diferencias observadas no se deben al azar, se analizó la significancia estadística mediante un test PERMANOVA, siendo la única variable que presentaba diferencias significativas entre dos grupos la variable "delivery" (p-valor= 0.02). Es por esto, por lo que se escogió dicha variable como aquella que mejor explicaba el comportamiento dicotómico de las muestras del estudio (Figura 17).

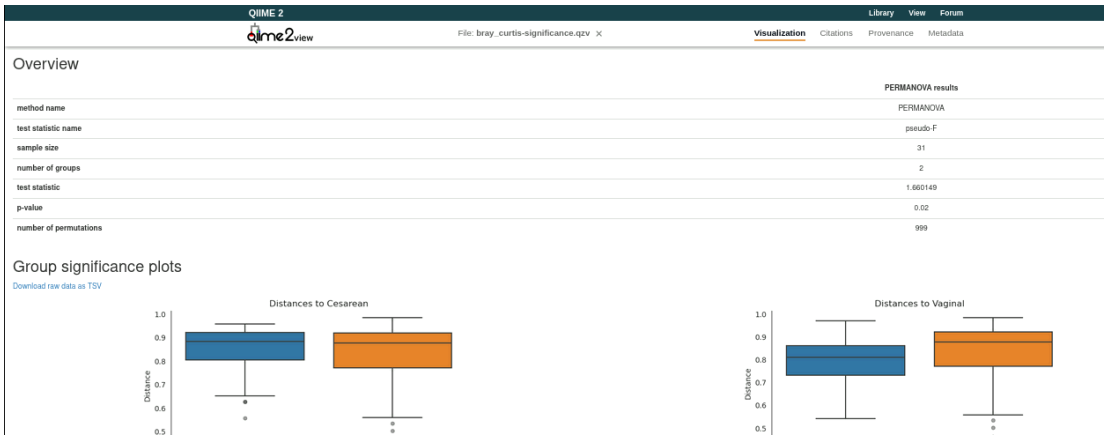

Figura 17. Resumen de la significancia de la prueba de índice beta Bray-Curtis para la variable "delivery". La imagen muestra un p-valor significativo (p-valor<0.05), por lo que los dos grupos son significativamente diferentes. Archivo: bray_curtis-significance.qzv.

A diferencia del índice de Bray-Curtis, el índice de Jaccard mide la disimilitud entre dos comunidades en función del número de especies compartidas y no compartidas, basándose exclusivamente en su presencia o ausencia, sin considerar su abundancia relativa.

Al analizar los resultados, se observó que la variable “delivery” fue la que mejor explicaba la diferenciación entre las muestras (Figura 18), mostrando un patrón similar al observado con el índice de Bray-Curtis. El test PERMANOVA aplicado a este índice confirmó que “delivery” era estadísticamente significativa (p-valor = 0.005), siendo nuevamente la única variable que mostraba diferencias significativas entre los grupos (Figura 19).

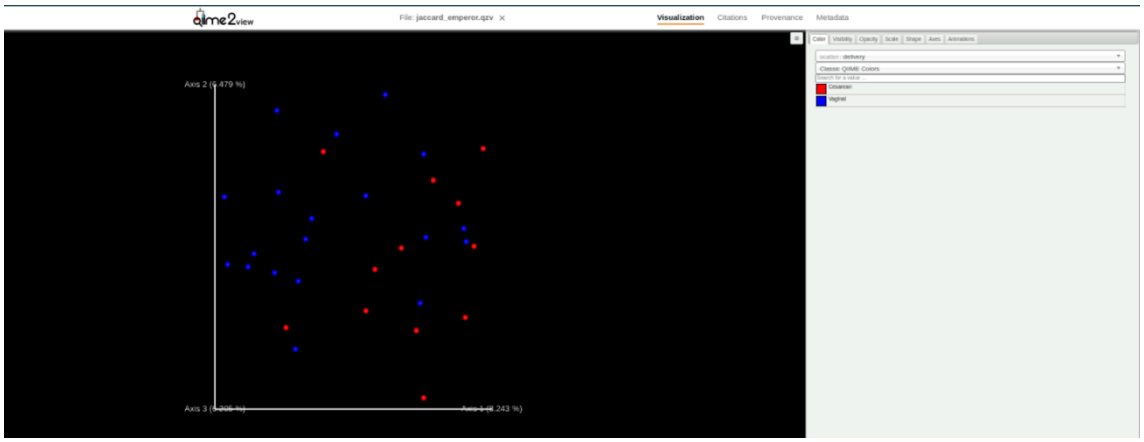

Figura 18. Matriz de puntos en 3D que representa la diversidad beta en dos grupos en función de la variable “delivery”. Archivo: jaccard_emperor.qzv.

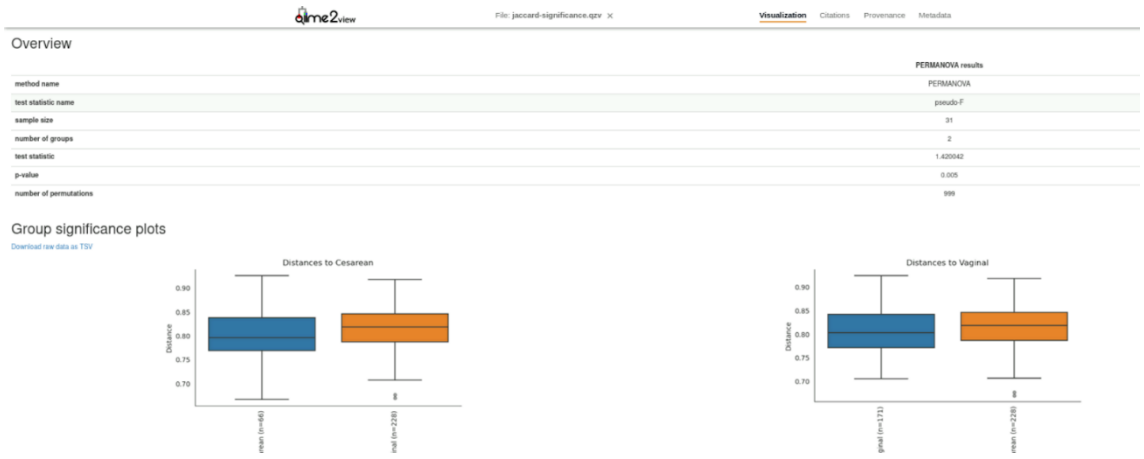

Figura 19. Resumen de la significancia de la prueba de índice beta de Jaccard para la variable “delivery”. La imagen muestra un p-valor significativo (p-valor<0.05), por lo que los dos grupos son significativamente diferentes. Archivo: jaccard-significance.qzv.

Taxonomía

En siguiente lugar, se procedió a la elaboración de un árbol filogenético, necesario para calcular métricas de diversidad como el índice de Faith y la distancia UniFrac. Existen dos enfoques principales para la construcción de árboles filogenéticos: uno basado en la inserción de fragmentos en árboles de referencia y otro *de novo*. En nuestro análisis, se optó por construir un árbol *de novo*, que se llevó a cabo en cuatro etapas: alineamiento de secuencias con MAFFT, enmascaramiento de regiones poco informativas, construcción del árbol mediante FastTree y, finalmente, su enraizamiento. Estas etapas están integradas en el pipeline "qiime phylogeny align-to-tree-mafft-fasttree", el cual genera tanto un árbol no enraizado, que muestra las relaciones entre las secuencias sin identificar el ancestro común, como un árbol enraizado, que sí permite identificar la rama correspondiente al ancestro común más reciente.

Sin embargo, antes de visualizar el árbol generado, sería de interés reconocer que taxones microbianos corresponden a cada ASV. Para ello se utilizó un clasificador específico para el estudio. Es importante tener en cuenta que la clasificación taxonómica fue realizada utilizando un clasificador basado en bases de datos antiguas, lo que puede conllevar a un mayor margen de error, menor precisión en la asignación taxonómica y una información incompleta para ciertos grupos microbianos.

En dicho archivo se muestra una tabla con los identificadores de cada ASV, la clasificación taxonómica asignada y el nivel de confianza asociado a cada asignación.

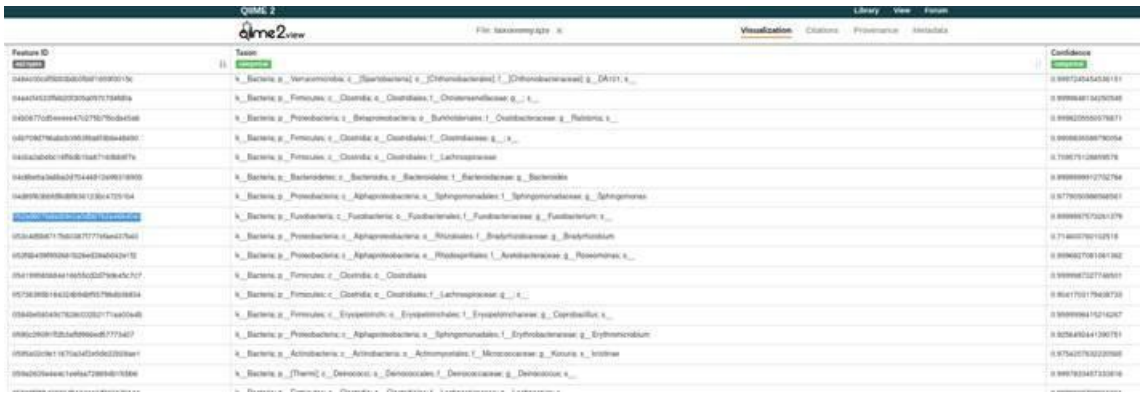

Figura 20. Clasificación taxonómica de las secuencias representativas (ASV) con su correspondiente nivel de confianza.

En el árbol filogenético generado, cada rama azul representa una ASV identificada en el estudio, y la estructura central refleja las relaciones evolutivas entre dichas secuencias (Figura).

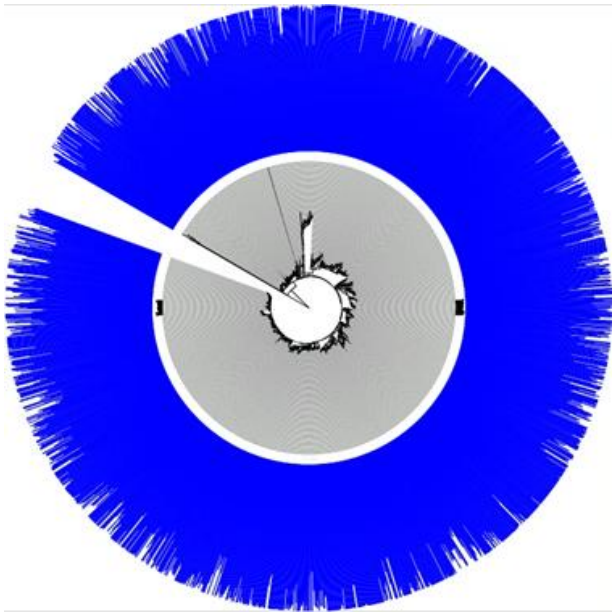

Figura 21. Representación circular del árbol filogenético enraizado generado.

Una vez generado el árbol filogenético, se puede proceder al cálculo de las métricas de diversidad mencionadas anteriormente. Atendiendo al Faith PD, se observa que únicamente la variable "delivery" mostró diferencias significativas en la diversidad filogenética entre los nacimientos por vía vaginal y por cesárea (p-valor = 0.023). En particular, los recién nacidos por cesárea presentaron una menor diversidad filogenética, lo que sugiere una menor variedad de funciones ecológicas y biológicas dentro de su comunidad microbiana. Esto podría explicarse por el hecho de que, en su mayoría, las especies presentes pertenecen al mismo filo y comparten una base genética muy similar (Figura).

En relación con las variables "anti_exposed_all" y "sex" no se obtuvo diferencias significativas, obteniendo un p-valor de 1 y 0.49 respectivamente.

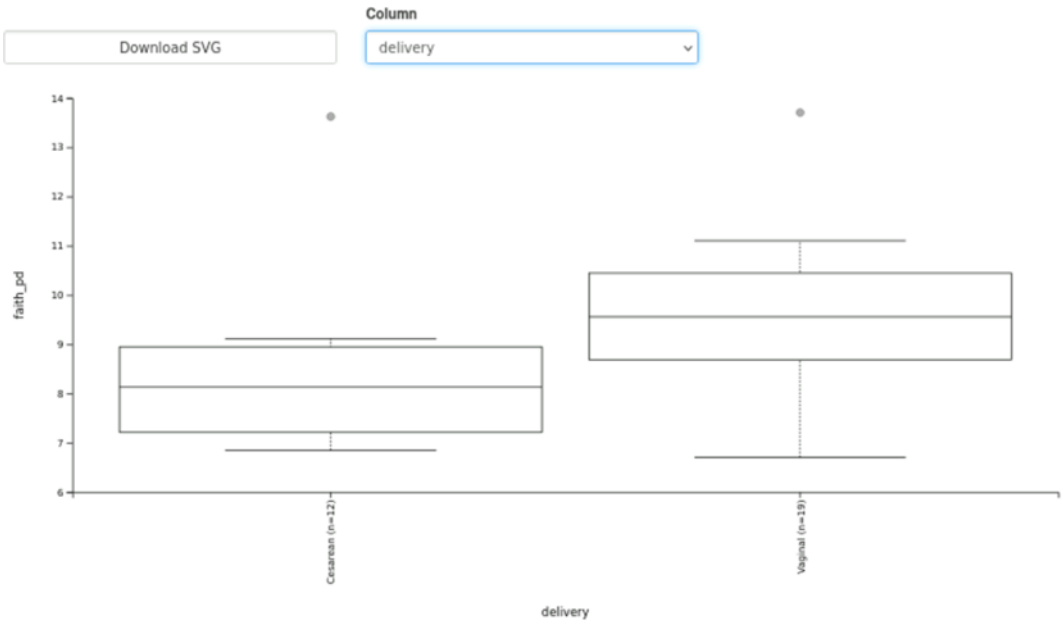

Figura 22. Boxplot del índice de diversidad Faith PD comparando nacimientos por cesárea y por vía vaginal.

Seguidamente se calculó el índice de UniFrac, el cual se encarga de analizar la disimilitud o diferencia entre comunidades microbianas presentes en las muestras, considerando su información filogenética. Existen dos variantes principales: el UniFrac no ponderado, que evalúa únicamente la presencia o ausencia de linajes (ignorando su abundancia relativa), y el UniFrac ponderado, que sí tiene en cuenta la abundancia relativa de cada linaje.

Al observar los gráficos generados con Emperor, se aprecia que la variable “delivery” es la única que muestra un cierto comportamiento dicotómico, a diferencia de las variables “sex” y “anti_exposed_all”. Sin embargo, al igual que en el resto de los análisis de diversidad beta, se aplicó un test PERMANOVA para evaluar si estas diferencias observadas podrían deberse al azar.

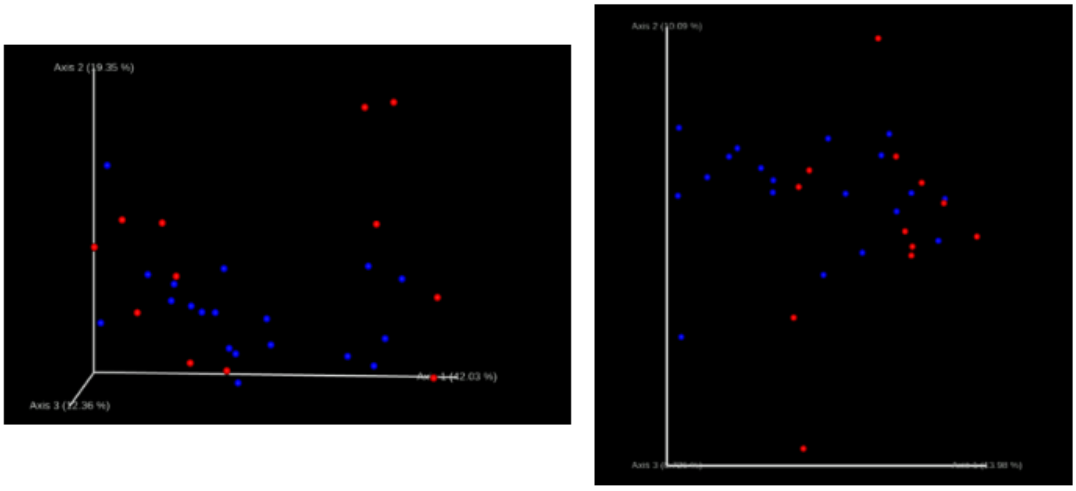

Figura 23. Representaciones de la diversidad beta mediante análisis UniFrac para la variable "delivery" UniFrac no ponderado.

Tras realizar el test PERMANOVA, se obtuvo un p-valor significativo (0.017) únicamente en el UniFrac no ponderado (Figura), a diferencia del UniFrac ponderado, el cual mostró un p-valor no significativo (0.253). Esto sugiere que las diferencias observadas entre los grupos se deben principalmente a la presencia o ausencia de ciertos linajes microbianos, y no tanto a su abundancia relativa.

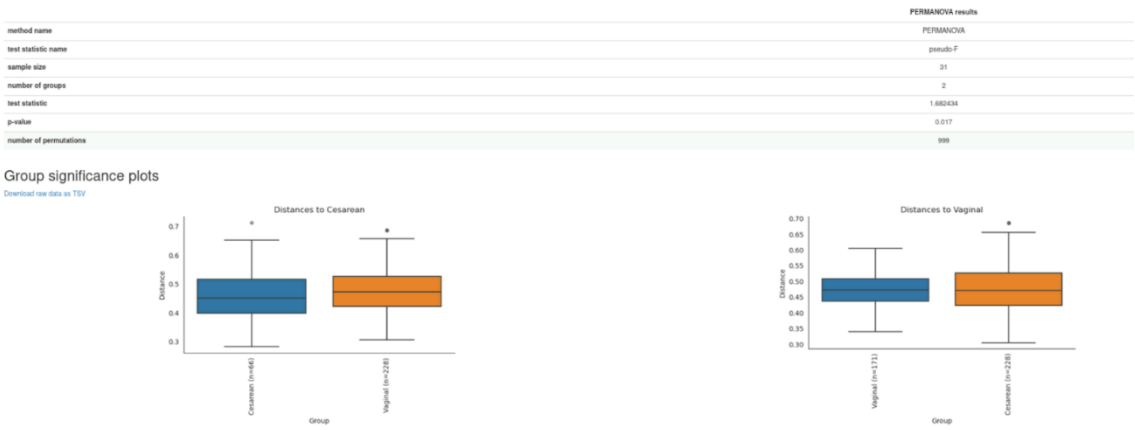

	PERMANOVA results
method name	PERMANOVA
test statistic name	pseudo-F
sample size	31
number of groups	2
test statistic	1.682434
p-value	0.017
number of permutations	999

Figura 24. Resultados del test PERMANOVA para el análisis con UniFrac no ponderado según la variable "delivery". No se observaron diferencias significativas (p = 0.017).

Otro de los objetivos de este estudio es identificar la composición taxonómica de cada una de nuestras muestras. Tal y como especificamos en el análisis de la diversidad, usaremos la variable "delivery" por su mejor comportamiento dicotómico, con el fin de explicar posibles diferencias en función del tipo de parto. Como podemos observar en el gráfico de barras, se observa que las muestras correspondientes a partos por cesárea presentan una mayor proporción de *Fusobacteria* y una menor presencia de *Verrucomicrobia*, en comparación con las muestras de partos vaginales, donde *Fusobacteria* está ausente y *Verrucomicrobia* aparece con mayor frecuencia.

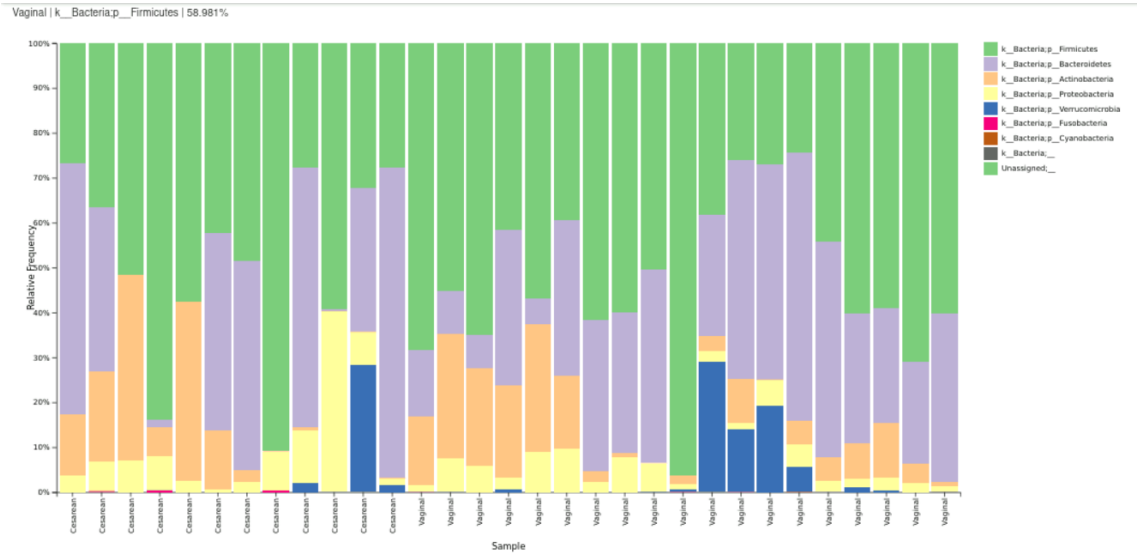

Figura 25. Composición taxonómica a nivel de filo en función del tipo de parto (*Cesárea o Vaginal*).

En el análisis taxonómico a nivel de filo para la variable "sexo", no se observaron grandes diferencias. Sin embargo, en el caso de la variable "anti_exposed_all", se apreciaron ligeras diferencias, como la presencia de *Fusobacteria* en el grupo que no estuvo expuesto a antibióticos.

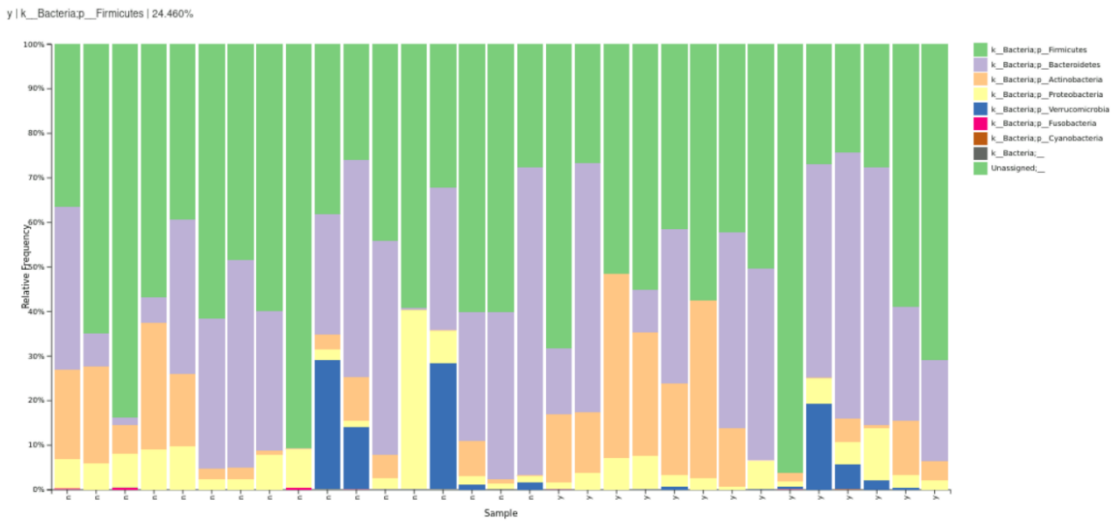

Figura 26. Composición taxonómica relativa a nivel de filo en función de la exposición a antibióticos.

Abundancia diferencial con ANCOM-BC

Una parte importante de un análisis de microbiota consiste en identificar qué ASV están en mayor o menor proporción entre diferentes grupos de estudio. Para ello, se utilizó ANCOM-BC, una alternativa a ANCOM que corrige dos fuentes importantes de sesgo: las fracciones de muestreo desiguales (sesgos específicos de la muestra) y las eficiencias de secuenciación diferenciales (sesgos específicos del taxón), permitiendo construir estimadores estadísticamente consistentes.

En primer lugar, al visualizar los resultados correspondientes a la variable "delivery", el análisis con ANCOM-BC a nivel taxonómico muestra que *Bacteroidetes uniformis* presenta un valor negativo de Log Fold Change (LFC), lo que indica una menor abundancia relativa en el grupo de cesárea en comparación con el grupo vaginal.

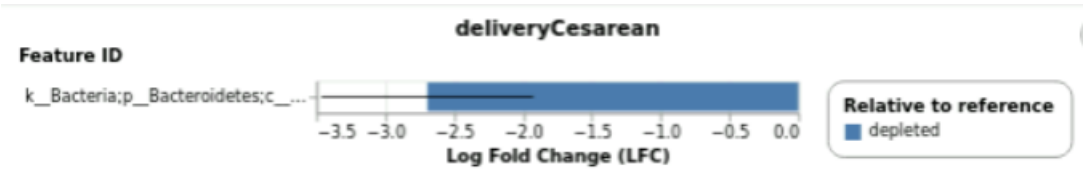

Figura 27. ANCOM-BC (nivel taxonómico). *Bacteroidetes uniformis* presenta un LFC negativo en el grupo cesárea.

A nivel de ASV, se observaron diferencias significativas en dos secuencias concretas: una correspondiente a *Faecalibacterium prausnitzii* y otra a *Bacteroidetes uniformis*. Ambas mostraron una menor abundancia en recién nacidos por cesárea, lo que sugiere que estas especies podrían estar más enriquecidas en nacimientos por vía vaginal**.**

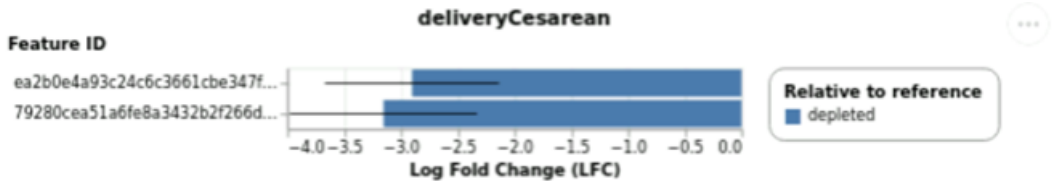

Figura 28. ANCOM-BC (nivel ASV). *Faecalibacterium prausnitzii* y *Bacteroidetes uniformis* presenta un LFC negativo en el grupo cesárea.

Respecto a la variable "sexo", se identificó, tanto a nivel taxonómico como de ASV, una misma bacteria perteneciente al filo *Firmicutes* y al género *Clostridium*, que presentó un valor de LFC positivo, lo que indica un enriquecimiento en el grupo femenino en comparación con el masculino.

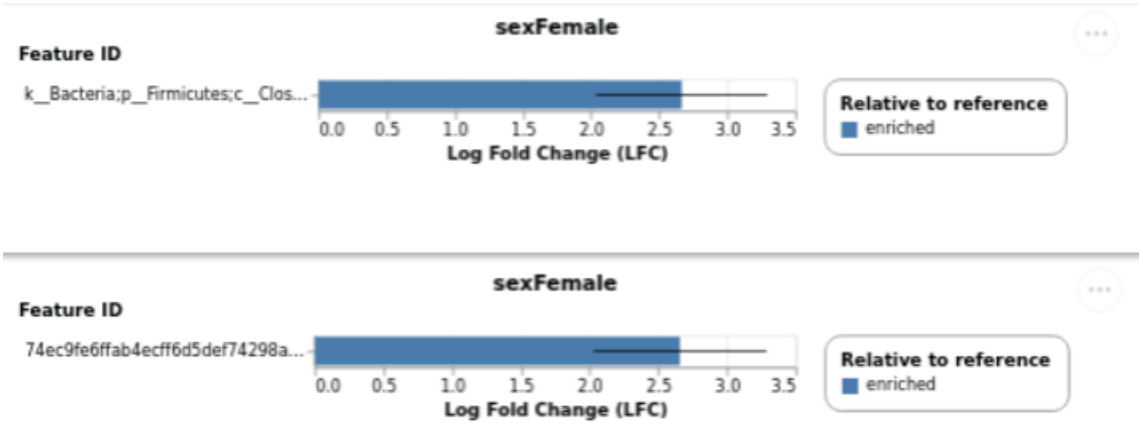

Figura 29. ANCOM-BC (nivel ASV y taxonómico). *Firmicutes Clostridium* presenta un LFC positivo en el grupo femenino.

Por último, la variable "anti_exposed_all" no mostró diferencias significativas ni a nivel taxonómico ni a nivel de ASVs, lo que corrobora lo previamente observado para dicha variable.

Se corroboró mediante BLAST que las secuencias de aquellos identificadores taxonómicos con una puntuación de confianza igual o mayor a uno, filtradas por “delivery” y por “sexo”, correspondían a las bacterias identificadas originalmente en la taxonomía. El resultado del ASV también fue exitoso.

Conclusiones

El análisis de la microbiota infantil a partir de los datos del estudio ECAM ha permitido identificar diferencias significativas en la composición y diversidad microbiana durante los primeros meses de vida. Tras los procesos de prefiltrado, denoising y normalización mediante rarefacción, se generó la base de datos para el análisis de diversidad, taxonomía y abundancia diferencial.

La aplicación de una profundidad adecuada de rarefacción permitió alcanzar un nivel de saturación en la mayoría de las curvas de diversidad, lo cual indicó que la cobertura de secuenciación fue suficiente para caracterizar la riqueza microbiana.

Los resultados apuntan a que el tipo de parto ya sea vaginal o por cesárea, puede influir significativamente en la composición de la microbiota entre los individuos, mostrando una mayor riqueza y diversidad en los nacidos por vía vaginal.

Esta diferencia también se refleja en la diversidad beta, donde se observan agrupamientos diferenciados según el tipo de parto, lo que indica una alteración global en la composición de la comunidad microbiana.

A nivel taxonómico, se observaron diferencias relevantes en la presencia de ciertos filos: las muestras de partos por cesárea presentaron una mayor proporción de *Fusobacteria* y una menor presencia de *Verrucomicrobia* en comparación con los partos vaginales, donde *Fusobacteria* estuvo ausente y *Verrucomicrobia* fue más común.

Fusobacteria, aunque presente en bajas concentraciones como parte de la microbiota normal, se ha asociado en exceso con inflamación y enfermedades como el cáncer colorrectal.[1] En cambio, *Verrucomicrobia*, se vincula con beneficios metabólicos y con la barrera intestinal, aunque su presencia en exceso podría afectar de forma negativa a la mucosa intestinal.[2]

Es importante tener en cuenta que la clasificación taxonómica fue realizada utilizando un clasificador de bases de datos antiguas, lo que puede implicar un mayor margen de error, menor precisión en la asignación y una posible información incompleta para ciertos grupos.

Debe tenerse en cuenta que los sujetos del estudio tienen únicamente 12 meses de edad, es posible que muchas de las diferencias microbianas entre grupos aún no se hayan manifestado plenamente.

Asimismo, los análisis de abundancia diferencial mediante ANCOM-BC revelaron una depleción significativa de especies beneficiosas como *Faecalibacterium prausnitzii* y *Bacteroides uniformis* en los nacidos por cesárea, lo que podría implicar un impacto negativo en funciones metabólicas e inmunológicas tempranas. Además, se detectó la presencia del filo *Fusobacteria* únicamente en los niños expuestos a antibióticos, lo que podría reflejar una alteración del ecosistema intestinal asociada a dicha intervención.

Estos hallazgos refuerzan la hipótesis de que la vía de nacimiento influye directamente en la colonización microbiana intestinal inicial, con posible impacto a futuro en la salud.

Bibliografía

1. Shang et al., 2018. "Fusobacterium nucleatum and colorectal cancer: A review."
2. Derrien et al., 2017. "Akkermansia muciniphila and its role in regulating host functions."